

# Distribuovaná kalmanovská filtrace při neznámém prostorově heterogenním šumu

Daniel Hnyk

Matematická informatika  
Katedra matematiky

Fakulta jaderná a fyzikálně inženýrská  
České vysoké učení technické v Praze

Obhajoba diplomové práce (2018)

# Cíl práce

## Návrh algoritmu...

...k distribuované kalmanovské filtraci v difuzní síti, kde každý uzel sítě může potenciálně mít jinou kovarianci šumu na stavovém procesu i na měřeních a tato kovariance je navíc neznámá.

## Řešení

Distribuovaný adaptivní kalmanův filtr za použití variačních Bayesovských metod.

# Cíl práce

## Návrh algoritmu...

...k distribuované kalmanovské filtraci v difuzní síti, kde každý uzel sítě může potenciálně mít jinou kovarianci šumu na stavovém procesu i na měřeních a tato kovariance je navíc neznámá.

## Řešení

Distribuovaný adaptivní kalmanův filtr za použití variačních Bayesovských metod.

# Bayesovská pravděpodobnost

- interpretace pravděpodobnosti
- Inference pro model  $M = \{P_{\theta} | \theta \in \Theta\}$
- chceme posteriorní pravděpodobnost dle

$$p(\mathbf{Z}|\mathbf{X}) = p(\mathbf{Z}) \cdot \frac{p(\mathbf{X}|\mathbf{Z})}{p(\mathbf{X})}$$

## Aproximace

- přímý výpočet  $p(\mathbf{A}|\mathbf{B})$  obvykle není možný
  - vzorkování (MCMC, Gibbs)
  - variační počet (Variační Bayes)
- aproximujeme pomocí jednodušší rodiny distribucí a hledáme tu nejbližší
- např. faktorizovatelné distribuce  $q(\mathbf{Z}) = \prod_{i=1}^M q_i(\mathbf{Z})$
- vzdálenost měříme pomocí Kullback-Leiblerovy divergence

$$\text{KL}(q||p) = - \int q(\mathbf{Z}) \ln \frac{p(\mathbf{Z}|\mathbf{X})}{q(\mathbf{Z})} d\mathbf{Z}$$


- optimalizační problém

$$q(\mathbf{Z}) = \underset{q(\mathbf{Z})\text{-fakt.}}{\operatorname{argmin}} \text{KL}(q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}))$$

- stále nejde přímo, ekvivalentní maximalizaci

$$\mathcal{L}(q) = \int q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z})}{q(\mathbf{Z})} d\mathbf{Z}$$

## Lower variational boundary



lepší kvalita!

# Coordinate ascent mean-field variational

- optimální řešení problému

$$q_i^*(\mathbf{Z}_i) \propto \exp\{\mathbb{E}_{-i}[\ln p(\mathbf{Z}_i, \mathbf{Z}_{-i}, \mathbf{X})]\}$$


- v praxi se postupuje iterativně
- vhodná volba prior distribucí zjednodušuje update
- elegantní reprezentace použije-li se forma exponenciální rodiny

# Kalmanův filtr

- používá se pro zpřesnění předpovědí modelu na základě měření
- optimální lineární filtr (v MSE) pokud:
  - model přesně reflektuje skutečnost
  - šum je Gaussovský bílý
  - kovariance šumu jsou přesně známy
- tato práce se zabývá rozšířením kdy 3. bod není splněn
- distributivní - více propojených agentů provádějící filtraci



## Vizuálně



## Pravděpodobností model

sjednotit značení vektorů! Rozumět kde se vzalo  $p(\mathbf{z})$

- odhady odpovídají

$$p(\vec{z}_k | \vec{x}_k) = N(\vec{z}_k; \mathbf{H}_k \vec{x}_k, \mathbf{R}_k)$$

$$p(\vec{x}_k | \vec{x}_{k-1}) = N(\vec{x}_k; F_{k|k-1} \vec{x}_{k-1}, \mathbf{Q}_k).$$

- cílem je odhadnout kovariační matice šumů:  $\mathbf{R}_k, \mathbf{Q}_k$
- konjugovaná apriorní je Inverzní Wishartova distribuce
- předpokládáme, že distribuce je faktorizovatelná

$$\begin{aligned} p(\Xi, \mathbf{z}_{1:k}) &= N(\mathbf{z}_k; \mathbf{H}_k \mathbf{x}_k, \mathbf{R}_k) N(\mathbf{x}_k; \hat{\mathbf{x}}_{k|k-1}, \mathbf{P}_{k|k-1}) \\ &\times \text{IW}(\mathbf{P}_{k|k-1}; \hat{t}_{k|k-1}, \hat{\mathbf{T}}_{k|k-1}) \text{IW}(\mathbf{R}_k; \hat{u}_{k|k-1}, \hat{\mathbf{U}}_{k|k-1}) \\ &\times p(\mathbf{z}_{1:k-1}) \end{aligned}$$

# Difúze

- více agentů – uzlů – provádí filtraci lokálně

Jak to reprezentují funkcí, topologie, více nodes

- vzájemně propojení dle dané topografie
- po  $n$  krocích si vymění informace o odhadech

# Bayesovský update


využitím „exponential family form“ se celý update zjednodušuje na

$$\begin{aligned}\Xi_{i+1}^n &\leftarrow \Xi^{n-1} + \begin{bmatrix} -\frac{1}{2}(\mathbf{P}_{k|k}^i + (\hat{\mathbf{x}}_{k|k}^i - \hat{\mathbf{x}}_{k|k-1})(\hat{\mathbf{x}}_{k|k}^i - \hat{\mathbf{x}}_{k|k-1})^T) \\ -\frac{1}{2} \end{bmatrix} \\ \Omega_{i+1}^n &\leftarrow \Omega^{n-1} + \begin{bmatrix} \mathbf{H}_k \mathbf{P}_{k|k}^i \mathbf{H}_k^T + (\mathbf{z}_k - \hat{\mathbf{x}}_{k|k}^i)(\mathbf{z}_k - \hat{\mathbf{x}}_{k|k}^i)^T \\ -\frac{1}{2} \end{bmatrix}\end{aligned}$$

## Shrnutí algoritmu


1. **In:**  $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \hat{u}_{k-1|k-1}, \hat{\mathbf{U}}_{k-1|k-1}, \mathbf{F}, \mathbf{H}, \mathbf{z}_k, \tilde{\mathbf{Q}}_{k-1}, \tau, \rho, N$
2. Predikce KF
3. Inicializace hyperparamtrů  $\Xi_{\text{init}}, \Omega_{\text{init}}, \hat{\mathbf{x}}_{k|k}^{(0)} = \hat{\mathbf{x}}_{k|k-1}, \mathbf{P}_{k|k}^{(0)} = \tilde{\mathbf{P}}_k$
4. **for**  $i$  in  $N$  **do**:
  - 4.1 Updatuj  $\Omega^i$  a na základě něho  $\mathbb{E}[\mathbf{R}_k]$
  - 4.2 Updatuj  $\Xi^i$  a na základě něho  $\mathbb{E}[\mathbf{P}_{k|k-1}]$
  - 4.3 Kalmanova korekce na základě  $\hat{\mathbf{x}}_{k|k}^{i+1}, \mathbf{P}_{k|k-1}^{i+1}$
5. **end for**
6. Difúze:  $\Xi_*^{i,t} = g(\Xi^{i,t}, \Xi^{1,t}, \dots, \Xi^{d,t}), \Omega_*^{i,t} = g(\Omega^{i,t}, \Omega^{1,t}, \dots, \Omega^{d,t})$
7. **Out:**  $\hat{\mathbf{x}}_{k|k}^{i+1}, \mathbf{P}_{k|k-1}^{i+1}, \Xi_*^{i,t}, \Omega_*^{i,t}$

# Testovací úloha




# Testovací úloha

Third and fourth components of the state vector




# Statický známý šum - srovnání






# Statický známý šum - 3 komponenta




# Proměnlivý šum - srovnání

Comparison of RMSE and STD for unknown variable noise




## Proměnlivý šum - 3 komponenta


$x_3$  - Unknown variable noise



# Proměnlivý šum - kovariance




## Distribučná verze - topologie




# Proměnlivý šum - srovnání

Comparison of RMSE and STD for diffused and non-diffused algorithm

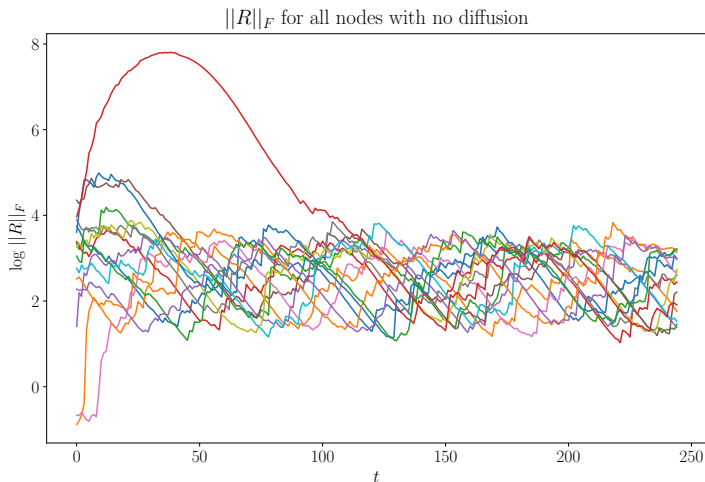


# Proměnlivý šum - srovnání kovariancí

Comparison of  $\|R\|_F$  before and after diffusion - 15 nodes

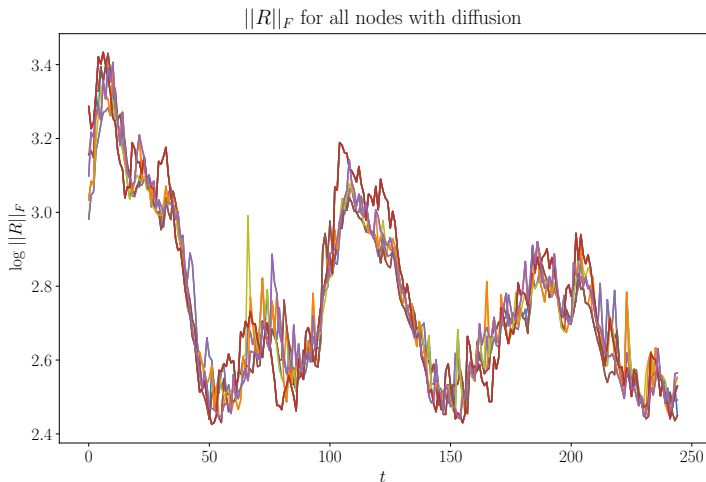


# Proměnlivý šum - kovariance bez difúze





# Proměnlivý šum - kovariance s difúzí



## Shrnutí

- navržený algoritmus má v případech neznámého šumu lepší výkon než základní verze filtru
- vede si zanedbatelně hůře v případě kdy je kovariance známá
- difúze přináší vyšší přesnost, nižší varianci a obranu proti divergenci
- vyžaduje však nastavení dalších 2 tuning parametrů

## Budoucí práce

- jaký vliv má topologie sítě a komunikace
- srovnání různých strategií difúzní funkce
- citlivost na jiné typy šumů než Gaussovský



# Ten problém 1

- no jo, to jsem přehlídl